


Stockage avancé

RAID / LVM



Quizz

Quelles sont les différentes couches de gestion du stockage depuis la couche physique jusqu'à la couche logique (les fichiers) ?





Quizz

Peut-on regrouper plusieurs disques au sein d'une seule partition ?


Peut-on mettre plusieurs systèmes de fichiers sur la même partition ?

Peut-on regrouper plusieurs partitions dans un même système de fichiers ?



Plan

- 1 - [Introduction](#)
- 2 - [RAID](#)
- 3 - [LVM](#)
- 4 - [SAN & NAS](#)





Introduction



Les besoins en stockage

Les besoins en stockage sont très variables en fonction des applications
Pour une application et donc pour les serveurs associés


- **Volume** : quel espace de stockage est nécessaire ?
 - à l'installation, évolution dans le temps
- **Performance** : débit et temps d'accès ?
 - l'accès aux données est-il un goulot d'étranglement ?
- **Sûreté** : quelle stratégie de conservation des données ?
 - Sauvegarde, tolérance de panne ?



Les supports de stockage

Offre en support de stockage contrainte par des paramètres économiques / coût / performance :

- Volume > 30 To (HAMR, SMR)
- Performance : HDD < SSD < NVMe
- Coût non linéaire
- Fiabilité ?





En résumé

- Disques durs (HDD)
 - Volume : 1 To -> 24 To
 - Performance $\approx$ 100aine de Mo/s
 - Tarif : 20-30aine €/To
- SSD
 - Volume : 250 Go -> 8 To
 - Performance $\approx$ 3 à 7 Go/s
 - Tarif : 100aine €/To



Fiabilité

En pratique : très variable

- Panne mécanique des disques durs
- Limite en nombre d'écritures des SSD

Plus on a de périphériques, plus la probabilité d'avoir une panne augmente

Au contraire du reste d'un ordinateur : changer le support de stockage ne suffit pas à relancer l'application



Cloisonner

Quelques constats :

- Un système de fichier est un espace partagé
- Contrôle applicatif de la volumétrie rare
- En général stockage plein => système/application plante

Une solution classique :

- Des espaces de stockages différents et étanches

En cas de débordement => seul le composant qui déborde est impacté



Dimensionner le stockage

Isoler les répertoires à forte variation

Quelques exemples :

- Les logs (`/var/log`)
- Les bases de données
- Les fichiers utilisateurs
- Les espaces de swap
- Les répertoires temporaires (`/tmp`)
- ...

Fixer un volume maximum à l'installation



Les limites

- Nombre de partitions limité
- Taille limitée par la taille max des disques
- Évolution après l'installation limitée et risquée



RAID



RAID

Redundant Array of Independent/Inexpensive Disks

Technique de **virtualisation** du **stockage** ayant pour **objectifs** :

- Agrandir la **taille** maximum disponible
- Améliorer les **performances** (débit)
- Améliorer la **fiabilité**

Sans avoir à recourir à de meilleurs disques qui peuvent être :

- Plus/trop chers
- Indisponibles



Idée générale

1987 - Université de Berkeley

Opposition au SLED (*Single Large Expensive Disk*)

Construire un volume/grappe/cluster RAID (*array*)

- Espace de stockage similaire à un disque
- À l'aide de plusieurs disques physiques
- Selon un niveau déterminant les propriétés de la grappe

Concept général disposant de nombreuses implémentations différentes



Les implémentations

RAID matériel

- Contrôleur disque (carte) installé sur un serveur

RAID logiciel

- Programme du/sur le système d'exploitation

RAID hybride

- Contrôleur physique nécessitant un logiciel



RAID matériel

Opérations effectuées directement au niveau du matériel

=> excellente performance & pas de consommation CPU

Transparent pour le système d'exploitation

=> boot sur la grappe RAID possible

Implémentations propriétaires - Spécifiques à chaque fabricant

=> en général incompatible

Configuration au boot (BIOS) et/ou via un logiciel à ajouter à l'OS

Souvent assez coûteux

Courant sur les serveurs d'entreprise



RAID logiciel

Fonctionnalité du système d'exploitation

- Assez souple d'utilisation
- Standard et compatible (pour le même système)
- boot sur la grappe RAID compliqué
- Consomme du CPU

Disponible sur :

- Linux - outil mdadm
- Windows



RAID hybride

Avantage : permet de booter le système sur le RAID

Pour le reste, on retrouve plutôt les inconvénients des 2 types :

- Problème de compatibilité
- Consommation CPU
- Fonctionnalités souvent limitées

Implémentations par les constructeurs de cartes mères



Les niveaux de RAID

Il existe plusieurs niveau de RAID en fonction des besoins

Ces niveaux peuvent ne pas tous être disponibles sur une implémentation donnée et il existe des variantes et des combinaisons




JBOD ou NRAID

Just a Bunch Of Disks - Non Redundant Array of Inexpensive Disks

Principe : Concaténation d'un ensemble de disques en un seul

- Tolérance aux pannes : médiocre
- Performances : identiques
- Gain en taille






RAID 0

Striping - Entrelaçage par bande

Principe : Données découpées et réparties sur n disques (en général 2)

- Capacité totale : $n \times$ capacité du plus petit disque de la grappe
- Gain en performance proportionnel au nombre de disques
- Gain en taille
- Fiabilité mauvaise (inversement proportionnelle au nombre de disques)






RAID 1

Mirroring - Disques miroirs

Principe : Données copiées sur n disques (en général 2)

- Capacité totale : capacité du plus petit disque de la grappe
- Performances quasi identiques
- Taille : *perte* de $n - 1$ disques
- Fiabilité excellente : tolère $n - 1$ pannes






RAID 4

Agrégation par bande avec parité

Principe : *Striping* sur n disques + 1 disque de parité (XOR)

3 disques minimum

- Capacité totale : $(n - 1) \times$ capacité du plus petit disque de la grappe
- Gain en performance proportionnel au nombre de disques (moins 1)
- Gain en taille
- Bonne fiabilité : tolère 1 panne
- Reconstruction coûteuse et/ou longue





RAID 5

Agrégation par bande avec parité répartie

Principe :


RAID 4 avec les informations de parité sont réparties sur les disques.

En général avec un mécanisme de rotation (tourniquet - *round-robin*).

Évite que le disque de parité soit un goulot d'étranglement en écriture

Avantage : un peu plus performant

Pour le reste : identique au RAID 4






RAID 6

RAID 5 avec duplication de la parité

Principe : n disques dont m ($=2$) disques de parité (4 disques minimum)

- Capacité totale : $(n - m) \times$ capacité du plus petit disque de la grappe
- Gain en performance
- Gain en taille
- Fiabilité excellente : tolère m panne
- Reconstruction plus coûteuse et/ou longue





Combinaison de RAID

Les plus courants :

RAID 0 + 1 (01)

Principe : un RAID 1 de grappes RAID 0

RAID 1 + 0 (10)

Principe : un RAID 0 de grappes RAID 1

De nombreuses autres variantes existent



Considérations générales

- Utilisation de disques identiques au sein d'une grappe
- Disque de spare => reconstruction automatique
- En général associé à des disques *hot plug* (remplaçable à chaud)
- Ne remplace pas les sauvegardes



LVM



Logical Volume Manager

Système de virtualisation du stockage permettant

- Plus de flexibilité et de facilité de gestion
- Des instantanés (*snapshots*)
- L'entrelacement (*striping*)
- La mise en miroir (*mirroring*)
- Opérations à chaud (création, redimensionnement, etc)




Architecture globale

Couche intermédiaire : *Volume Group* (VG)

- Disques : *Physical Volume* (PV)
- Regroupés dans un groupe de volume
- Découpé en *logical volume* (LV)

Chaque volume logique porte son propre système de fichier (FS)





Les volumes physiques

Un périphérique de stockage = Un volume physique (PV)

- Une partition
- Un disque complet
- Un volume RAID
- Un stockage distant (SAN)

Recommandation : faire une partition même pour un disque complet
=> Un MBR ou un GPT avec une partition étiquetée LVM
évite que les logiciels ne gérant pas LVM considère le disque
vide

Les groupes de volumes

Un groupe de volumes (VG) = un ensemble de (au moins 1) PV

- Couche d'abstraction

Taille du VG = Σ tailles des PV

Unité d'allocation : Physical Extends (PE)

Recommandation :

- Un VG par type de PV
- Regrouper des PV aux caractéristiques similaires (performance, fiabilité, usage)



Les volumes logiques

Un VG est découpé en volumes logiques (LV)

- Correspondent aux partitions habituelles
- Taille exprimée en nombre de *Logical Extends* (LE)
- Taille des LE = taille des PE
- Supportent un système de fichier

Un LV peut-être en RAID (0, 1, 4, 5, 6, 10)

Un LV peut-être une copie instantanée (snapshot) d'un autre LV

La copie à l'écriture

La création de copies instantanées est basée sur un mécanisme :
Copy-On-Write (COW) ou copie à l'écriture

Principe :

- À la création : les deux LV référence les mêmes données
- C'est seulement lors de modifications que la copie est faite

Conséquence :

- Création d'un *snapshot* est très rapide
- Un *snapshot* consomme peu de place
(métadonnées + modifications)

Redimensionnement à chaud

LVM supporte le redimensionnement à chaud des LV

- On peut agrandir un LV (dans la limite de la place disponible dans le VG) => sûr
- On peut rétrécir un LV => risqué
 - Attention aux données présentes !
 - LVM n'a pas connaissance de l'emplacement des données

Mais tous les systèmes de fichiers ne le supportent pas

- ext4 : oui
- XFS : non



Réduire la taille

Pour limiter les risques lors de diminution de la taille

- Réduire la taille du système de fichier (déplace les données)
 - Choisir une taille légèrement inférieure à la cible
- Réduire la taille du LV
- Modifier la taille du FS en le laissant prendre toute la place disponible

Reste une opération dangereuse

=> Une mauvaise manipulation = perte de données



Augmenter l'espace disponible

Quand un VG n'a plus assez d'espace disponible

=> Ajout d'un nouveau PV

L'espace ajouté par le nouveau disque devient disponible pour l'ensemble des LV du VG





Stocker via le réseau

Alternative au stockage local => stockage via le réseau

- Mutualisation à l'échelle d'un ensemble de machines
- Une seule gestion pour des machines
- Machines déplaçables (Notamment machines virtuelles)

2 approches :

- SAN : *Storage Area Network*
- NAS : *Network Attached Storage*



NAS

Serveur de stockage en réseau

- Idée ancienne : accéder à un système de fichiers distant

Nombreux protocoles :

- NFS ([Network File System](#)) : Classique du monde Unix
 - Permet de monter un système de fichier distant
- SMB ([Server Message Block](#)) : Approche Windows (aka CIFS)
 - Permet d'avoir des disques distants (et plus)
- [FTP](#), [SFTP](#)...

⚠ Impact fort sur le réseau => nécessite un réseau de bonne qualité



SAN

Réseau de stockage

- Réseau spécialisé (dédié) stockage/sauvegarde

Principe : Accès distant à des périphériques de blocs (bas niveau)

Baies de stockage (serveurs spécialisés)

- Disques nombreux - Grand RAID

Protocoles spécialisés :

- Fibre Channel : SCSI un LAN spécifique
- iSCSI : SCSI sur IP
- FCoE : Fibre Channel sur Ethernet





En conclusion

- Réflexion autour des problématiques de stockage
- Les systèmes RAID
- LVM
- Le stockage sur le réseau (NAS/SAN)

Pour aller plus loin

Les systèmes de fichiers de nouvelles générations

- [ZFS](#)
- [btrfs](#)